

基于眼底图像的视网膜血管分割与血管形态特征分析实验报告

课程实践 · 数据集 FIVES · 2026 年 9 月

一、数据集说明与预处理方法

1.1 数据集介绍

FIVES (Jin 等, 2022) 是专为视网膜血管分割发布的大规模公开数据集, 包含 800 张 2048×2048 的彩色眼底照片, 每张都配有一名眼底影像专家逐像素标注的血管金标准。800 张图按官方划分: 600 张训练、200 张测试, 来自健康与多种眼底病变受试者, 图像在亮度、对比度、病灶干扰上的多样性明显超过传统 40 张规模的小数据集 (如 DRIVE), 训练出的模型泛化性更有说服力。

血管分割的下游价值在于形态定量: 血管密度、直径分布、总长度、迂曲度、分形维数等指标与高血压、糖尿病视网膜病变等疾病相关, 而细小血管末梢恰恰是最难分割、又最具临床信息量的部分。本实验在分割之外同时做形态分析, 评估模型输出“够不够格”做下游统计。

1.2 数据获取

数据从 Hugging Face 公开镜像 (tyluan/FIVES) 下载, 为 4 个 parquet 分片; 还原后核对: 600 张训练全图与 200 张测试全图, 图像与掩膜一一对应, 共约 1.8 GB。

1.3 预处理与裁块

2048×2048 的整图直接进网络太慢也不必要, 预处理分三步。第一步把整图双三次缩放到 1024×1024 (保留细血管的同时把数据量降为四分之一); 第二步裁成 2×2 不重叠的 512×512 块, 训练集得到 2400 块、测试集 800 块, 每块都带自己的血管金标准; 第三步对每块取绿色通道 (血管与背景对比最高) 做 CLAHE 对比度增强, 并按“灰度大于 10”自动生成视野 (FOV) 掩膜——评估只在视野内统计, 避免黑色背景虚高指标。

表 1 数据规模

集合	全图数	512×512 块数	用途
训练集	600	2400	训练（其中 120 块做验证选最优权重）
测试集	200	800	最终评估，训练过程完全不可见

二、实验方案（模型原理和改进）

2.1 基线：U-Net

基线用 U-Net（Ronneberger 等，2015）：编码器四级卷积下采样、解码器转置卷积上采样并与对应分辨率的编码特征拼接（跳跃连接），输出单通道 logits。跳跃连接让深层语义与浅层细节互补，是医学分割的标准基线。首层通道 32，输入 512×512，训练用 BCE+Dice 复合损失。

2.2 改进一：注意力门（Attention U-Net）

标准跳跃连接会把浅层特征原样送入解码器，其中包含大量背景响应。改进版在每级跳跃连接处插入注意力门：用深层特征给浅层特征逐位置打分（两个 1×1 卷积相加过 ReLU 再过 sigmoid），抑制背景、保留血管区域，相当于给跳跃连接装了个可学习的空间滤波器。

2.3 改进二：Tversky 损失

血管像素只占视野内约 9%，普通交叉熵偏向保守、细血管漏检多。Tversky 损失是 Dice 的推广，允许分别加权假阳性和假阴性：本实验取 $\alpha=0.3$ 、 $\beta=0.7$ ，惩罚漏检是误检的 2.3 倍，直接换召回率——形态分析依赖细血管完整性，这笔交换是划算的。

2.4 训练配置

表 2 训练配置

配置项	基线	改进版
模型	U-Net	注意力 U-Net
损失	BCE+Dice	Tversky ($\alpha=0.3$, $\beta=0.7$)
数据增强	随机翻转 / 90° 旋转	同左
优化器	Adam, 学习率 1e-3, 余弦退火	同左
轮数 / 批大小	15 轮 / 4	同左
模型选择	验证 120 块上 Dice 最优权重	同左

两个模型的数据、轮数、优化器完全一致，唯一变量是注意力门和损失函数。实验在单张 RTX 4090 上进行，每个模型训练约 20 分钟，随机种子固定，结果可复现。

三、评价指标

所有指标只在视野内、逐块计算后取均值（自动生成的 FOV 掩膜剔除黑边与纯背景的影响）。血管分割是不平衡问题，敏感性与特异性要成对看。

表 3 评价指标

指标	含义	为什么看它
Dice	预测与金标准的重叠度	分割主指标
IoU	交并比	比 Dice 更严格
敏感性 SE	真实血管找回来多少	细血管漏检越少越高
特异性 SP	真实背景判对多少	误检越少越高
准确率 Acc	总体像素判对比例	不平衡时会被背景抬高，参考用
AUC	ROC 曲线下面积	与阈值无关的排序能力

四、实验结果与分析

4.1 分割指标

表 4 测试集分割指标（n=800 块）

指标	基线 U-Net (BCE+Dice)	注意力 U-Net (Tversky)
Dice	0.8713 ± 0.140	0.8575 ± 0.135
IoU	0.7904 ± 0.153	0.7676 ± 0.146
敏感性 SE	0.8602 ± 0.156	0.8957 ± 0.150
特异性 SP	0.9912 ± 0.006	0.9833 ± 0.009
准确率 Acc	0.9824 ± 0.009	0.9783 ± 0.010
AUC	0.9900 ± 0.023	0.9708 ± 0.047

两个模型的 Dice 都在 0.86 以上、AUC 在 0.97 以上，明显超过文献里小数据集（DRIVE, 40 张图）上 0.79–0.82 的常见水平——大规模标注带来的收益是实打实的。改进版（Tversky）的规律与设计意图一致：敏感性从 0.860 升到 0.896（+3.6 个百分点，细血管漏检变少），代价是特异性从 0.991 降到 0.983；Dice 略降 1.4 个百分点，属于用精确度换召回的预期交换。

4.2 训练过程与定性结果




图 1 训练曲线（高斯平滑，验证 Dice 为 120 个验证块均值）

两个模型都在第 10 轮后进入平台：基线验证 Dice 稳定在 0.91 附近，改进版 0.90。2400 个训练块的数据量下，模型没有出现拟合发散（训练损失与验证 Dice 同步收敛）。




图 2 测试块定性对比：增强图 / 金标准 / 基线 / 改进版

定性看，主干血管两个模型都分得很干净；差别集中在细末梢与血管边缘：改进版在末梢处“画得更满”（对应 SE 提升），基线的边缘更干净（对应 SP 更高）。

4.3 血管形态特征分析

对 800 个测试块分别做形态定量（骨架化 + 距离变换），金标准与两个模型预测的均值对比见表 5。

表 5 形态特征均值对比（金标准 vs 模型预测）

特征	金标准	基线 U-Net	注意力 U-Net
血管密度（视野内）	0.0937	0.0918	0.1019
平均直径（像素）	6.67	6.92	7.24
中位直径（像素）	6.16	6.51	6.83
血管总长度（像素/块）	2658	2461	2629
迂曲度（简化口径）	3.92	3.36	3.53
分形维数（盒计数）	1.394	1.376	1.394




图 3 血管直径分布对比（金标准与两模型）

形态统计能读出模型误差的“性质”：预测血管平均粗 0.3–0.6 像素（模型倾向把细血管预测得偏粗）；基线密度几乎与金标准一致但总长度只有 92.6%（细末梢断裂），改进版靠 Tversky 把长度恢复到 99.0%；两者都低估迂曲度（弯曲的细末梢丢失让骨架变直），分形维数基本保持（分支复杂度没有塌缩）。结论：如果下游做疾病筛查的形态统计，改进版预测更接近金标准；若更在乎假阳性，基线更稳。

4.4 复现方式

全部流程可由仓库脚本重跑：prepare_fives.py 负责下载还原、缩放裁块与视野掩膜生成；train.py 以相同种子分别训练基线与改进版；evaluate.py 输出逐块指标与可视化；morphology_batch.py 输出形态统计与直径分布图。逐块指标明细（800 块）与最优权重都保留在 outputs/ 目录。

五、改进方向

按值得做的程度排序：

1. 拓扑连续性约束（clDice 损失）：形态分析显示模型最大短板是末梢断裂（总长度 93–99%、迂曲度低估 10–14%），clDice 直接优化骨架连通性，是对症的一步。
2. 整图推理拼接：目前按块评估，块边界处血管被截断；把 4 块预测拼回整图再评估，指标会更贴近真实使用场景。
3. 高分辨率细化：在 1024 整图上做滑窗重叠推理 + 边界融合，减少缩放造成的细血管丢失。
4. 跨数据集泛化：在 FIVES 训练、DRIVE/CHASE 上零样本测试，检验人群与设备差异下的稳健性。
5. 把形态量直接纳入模型选择：本实验已经显示“Dice 接近、形态偏差不小”，下游要用形态统计时，应按形态误差而不是只按 Dice 选模型。